

“Klasifikasi Katarak Berdasarkan Citra Mata Menggunakan Metode Support Vector Machine (SVM) dengan Ekstraksi Fitur GLCM dan HOG”

Anggota Kelompok:

202210370311424 Ulva Nuha Muvidah

202210370311431 Ismi Dwi Junianti

202210370311435 Hamdatul Mabruroh

Business Objective/tujuan

Tujuan dari proyek ini adalah untuk membangun sistem klasifikasi citra mata yang dapat mendeteksi kondisi Normal dan Katarak secara otomatis menggunakan algoritma Support Vector Machine (SVM).

Model SVM dipilih karena kemampuannya dalam melakukan pemisahan kelas secara optimal pada data berdimensi tinggi dan efisien meskipun jumlah data terbatas. Sebelum proses klasifikasi, citra retina diekstraksi fiturnya menggunakan metode: HOG (Histogram of Oriented Gradients) untuk mendeteksi pola tepi dan struktur retina, LBP (Local Binary Pattern) untuk menangkap tekstur lokal retina, Fitur warna (mean dan standar deviasi RGB) untuk mendeteksi perbedaan distribusi warna pada mata katarak.

Model ini diharapkan dapat membantu tenaga medis dalam proses skrining awal katarak, khususnya di daerah yang memiliki keterbatasan alat diagnostik dan tenaga dokter spesialis mata.

Original Data

- Urgensi topik/kasus yang dipilih.

Proyek ini penting karena prevalensi katarak di Indonesia masih tinggi dan banyak daerah yang kekurangan dokter spesialis mata. Dengan adanya sistem klasifikasi otomatis berbasis machine learning, tenaga kesehatan umum dapat melakukan skrining awal sebelum pasien dirujuk ke dokter spesialis. Hal ini diharapkan dapat mempercepat deteksi dini katarak dan menurunkan angka kebutaan akibat keterlambatan diagnosis.

- Data yang digunakan.

- o Deskripsi singkat : Dataset **Ocular Disease Recognition (ODIR)** merupakan kumpulan data citra retina yang dikumpulkan untuk pengenalan berbagai penyakit mata, termasuk katarak, **glaukoma, diabetic retinopathy, dan lain-lain**. Dataset ini bersumber dari Kaggle, berisi gambar fundus retina (mata bagian dalam) dan label diagnosis untuk setiap pasien. Total keseluruhan data citra yang digunakan sebanyak 3.411 gambar, yang kemudian dibagi menjadi data train, validation, dan test untuk proses pelatihan dan evaluasi model.
- o Jelaskan data mining task yang akan digunakan

Classification (Klasifikasi) : Memprediksi apakah citra mata termasuk kategori Cataract atau Normal.

- o Sumber data (sertakan link).

<https://www.kaggle.com/code/aneeshjosyula/ocular-disease-recognition/input>

- **Urgensi:**


- Katarak merupakan penyebab kebutaan nomor satu di dunia, termasuk di Indonesia.
- Pemeriksaan diagnosis katarak masih membutuhkan dokter spesialis mata dan alat yang mahal.
- Dengan sistem berbasis Machine Learning, skrining awal dapat dilakukan lebih cepat dan efisien, terutama untuk daerah terpencil.

- **Data:**

- Dataset : ODIR-5K- Ocular Disease Intelligent Recognition
- Sumber : Kaggle
- Jumlah Data : 3.411
- Kelas : 0 - Normal Fundus
1 - Cataract
- Kategori Kelas : Normal Fundus & Cataract

Dataset berisi gambar retina bagian kiri dan kanan dari pasien, dengan label diagnostik yang dijelaskan pada file Excel.

Tabel 1. Contoh Dataset Citra Mata Original

Nama Gambar	Contoh Citra	Label Kelas	Ukuran Asli
0_left		Cataract	2304 x 1728
112_right		Cataract	1956 x 1934
8_left		Normal	2400 x 2400
8_right		Normal	2400 x 2400

- **Task: Klasifikasi** (Memprediksi kondisi mata berdasarkan citra retina) dengan label kelas 0 = Normal dan 1= Cataract.

Data Pre-processing

Pada tahap ini dilakukan beberapa proses untuk menyiapkan data citra retina sebelum digunakan dalam pemodelan.

- a. Data Cleaning
 - Menghapus entri yang tidak memiliki label valid (misal: Other)
 - Menghapus data yang file citranya rusak atau tidak ditemukan
 - Hanya menyisakan kelas Normal dan Cataract
- b. Data Transformation (Citra - Format Seragam)
 - Resize: 128 x 128 piksel
 - Format Warna: RGB Seragam
 - Scaling Pixel: Normalisasi nilai piksel ke rentang 0-1 ($\text{img}/255.0$)
- c. Data Normalization
 - Normalisasi piksel dilakukan untuk menetralkan efek intensitas cahaya yang berbeda (Min: 0.0, Max: 0.0039)
- d. Data Augmentation

Digunakan untuk menambah variasi citra, terutama pada kelas minoritas (Cataract), dengan parameter:

- Digunakan untuk menambah variasi dataset dan mencegah overfitting.
- Rotasi $\pm 15^\circ$
- Translasi horizontal/vertical 10%
- Zoom 10%
- Horizontal flip

Untuk menyeimbangkan dataset, kelas **Cataract** di-*augment* hingga **3 kali lipat** jumlah data awal.

- e. Feature Extraction (Metode Klasik)

Ekstraksi fitur dilakukan untuk mengubah citra menjadi vektor numerik menggunakan metode:

- HOG (Histogram Of Oriented Gradients) untuk menangkap tepi & struktur global.
- LBP (Local Binary Pattern) untuk menangkap tekstur lokal retina
- Statistik warna (mean dan std RGB) → menangkap perbedaan intensitas warna pada mata katarak.

Tabel 2. Contoh Dataset Citra Mata Setelah Preprocessing

Nama Gambar	Contoh Citra	Label Kelas	Ukuran
cataract_0001		Cataract	128 x 128
cataract_0070		Cataract	128 x 128
normal_0006		Normal	128 x 128
normal_0007		Normal	128 x 128

Data Transformation

Tahap ini mengubah fitur menjadi bentuk numerik untuk input model Machine Learning.

- a. Feature Normalization
 - Menggunakan StandardScaler
 - Nilai fitur → distribusi normal (mean=0, std=1)
- b. Data Reduction (PCA)
 - Menggunakan Principal Component Analysis

- **PCA (Principal Component Analysis):** Mengurangi dimensi dari 8.158 fitur menjadi **100 komponen utama**, dengan informasi variansi $\pm 90\%$.

Data Mining (Model SVM)

- Algoritma


Algoritma yang digunakan adalah Support Vector Machine (SVM). SVM merupakan algoritma klasifikasi yang bekerja dengan mencari hyperplane terbaik untuk memisahkan dua kelas (mata normal dan katarak) berdasarkan fitur yang telah diekstraksi (warna, tekstur, atau bentuk). Pemilihan SVM didasarkan pada kemampuannya menangani data berdimensi tinggi dan menghasilkan batas keputusan yang optimal, sehingga cocok untuk klasifikasi citra medis seperti deteksi katarak.

- Skenario eksperimen sederhana.
 - Data split : 80% Training, 20% testing
 -
 - Evaluasi : Menggunakan classification report dan confusion matrix
 - Metrik: Accuracy, Precision, Recall, dan F1-score
- Evaluasi

Tabel. 3 Classifiaction Report (SVM)

Kelas	Precision	Recall	F1-score	Support
Normal	0.97	0.97	0.97	620
Cataract	0.92	0.92	0.92	250
Accuracy	-	-	0.95	870
Macro AVG	0.94	0.95	0.95	870
Weighted AVG	0.96	0.96	0.96	870

Berdasarkan **Tabel 3**, model SVM menunjukkan performa yang sangat baik dengan nilai accuracy sebesar 96%. Kelas Normal memiliki nilai precision dan recall sebesar 0.97, sedangkan kelas Cataract memiliki nilai 0.92. Hal ini menunjukkan bahwa model mampu mengklasifikasikan citra dengan tingkat kesalahan yang rendah.



Gambar 1. Confusion Matrix (SVM)

Pada Gambar 1, Confusion matrix memperlihatkan bahwa sebagian besar data diklasifikasikan dengan benar, dengan 602 citra Normal dan 231 citra Cataract yang terdeteksi benar. Hanya terdapat sedikit kesalahan klasifikasi, yaitu 18 data Normal yang salah terdeteksi sebagai Cataract dan 19 data Cataract yang salah terdeteksi sebagai Normal.

Tabel 4. Hasil Error Analysis

Contoh Kesalahan Klasifikasi Oleh SVM	
Pred: Cataract True: Normal	

Pred: Normal True: Cataract	
Pred: Normal True: Cataract	

Error Analysis :

- FP (False Positive): Citra mata normal salah diklasifikasikan sebagai katarak karena adanya pantulan cahaya atau glare.
- FN (False Negative): Citra mata katarak diklasifikasikan sebagai normal karena katarak ringan sulit dibedakan secara visual.

Kesalahan ini menunjukkan bahwa beberapa fitur visual belum cukup kuat membedakan dua kondisi mata.

Knowledge Interpretation

a. Arsitektur CNN dari Scratch

Model CNN custom dirancang dengan arsitektur deep learning yang komprehensif:

- 4 Blok Konvolusional dengan filter meningkat (32, 64, 128, 256)
- Batch Normalization dan Dropout untuk regularisasi
- Fully Connected Layers dengan 512 dan 256 neuron
- Total Parameter: 9,658,369 parameter yang dapat dilatih

b. Transfer Learning dengan MobileNetV2


Menggunakan arsitektur pre-trained MobileNetV2 yang dioptimalkan untuk CPU:

- Base Model: MobileNetV2 dengan weights ImageNet
- Custom Classifier: Dense layers dengan 128 neuron
- Strategi: Two-phase training (frozen base + fine-tuning)

c. Hasil Pelatihan dan Evaluasi

Tabel 5. Perbandingan Komprehensif Tiga Pendekatan Model

Model	Accuracy	Precision	Recall	F1-score
SVM + Feature Engineering	95.52%	94.48%	94.59%	94.53%
CNN dari Scratch	96.09%	90.30%	96.30%	95.33%
Transfer Learning + Fine-tuning	71.26%	35.63%	50.00%	41.61%



Gambar 2. Visualisasi Perbandingan Model

d. Analisis Performa Model

CNN dari Scratch menunjukkan performa terbaik dengan:

- Accuracy tertinggi: 96.09%
- Recall terbaik: 96.30% (sangat penting untuk deteksi katarak)
- F1-Score terbaik: 95.33%

Kelebihan CNN dari Scratch:

- Mampu mempelajari feature representation secara spesifik untuk dataset katarak
- Lebih robust terhadap variasi dalam data medis
- Tidak bergantung pada pre-trained weights yang mungkin tidak optimal untuk domain medis.

Keterbatasan Transfer Learning:

- MobileNetV2 yang di-train pada ImageNet mungkin kurang optimal untuk citra medis
- Membutuhkan komputasi yang lebih intensif
- Hasil fine-tuning yang kurang optimal mungkin disebabkan oleh domain gap yang besar.

Implementasi dan Deployment

a. Pemilihan Model Terbaik

Berdasarkan evaluasi komprehensif, CNN dari Scratch dipilih sebagai model produksi dengan pertimbangan:

- F1-Score tertinggi (95.33%)
- Recall yang excellent (96.30%) untuk mendeteksi kasus katarak
- Arsitektur yang optimal untuk karakteristik citra fundus

b. Prediksi pada Data Testing

Model terbaik berhasil melakukan prediksi pada 1000 gambar testing:

- Normal: 909 gambar (90.9%)
- Cataract: 91 gambar (9.1%)

Hasil prediksi disimpan dalam file `test_predictions_final.csv`

c. Konfirmasi Kualitas Model

- Training Stability: Loss convergence yang smooth
- Validation Performance: Konsisten tinggi across metrics
- Generalization: Mampu memprediksi data unseen dengan baik

Kesimpulan

Berdasarkan seluruh eksperimen yang telah dilakukan, dapat disimpulkan bahwa sistem klasifikasi katarak berbasis deep learning berhasil dikembangkan dengan performa yang sangat memuaskan. Di antara ketiga pendekatan yang diuji—SVM dengan ekstraksi fitur HOG dan LBP, CNN dari scratch, dan Transfer Learning dengan MobileNetV2—model **CNN dari scratch** terbukti paling unggul dengan mencapai akurasi 96,09%, recall 96,30%, dan F1-Score 95,33%. Keberhasilan ini menunjukkan bahwa arsitektur CNN custom yang dirancang khusus mampu mempelajari representasi fitur yang optimal untuk karakteristik citra fundus mata, mengungguli pendekatan traditional machine learning maupun transfer learning. Model terbaik tersebut kemudian berhasil diaplikasikan pada data testing dengan memprediksi 909 gambar sebagai normal dan 91 gambar sebagai katarak, yang merefleksikan kemampuannya dalam melakukan skrining otomatis. Hasil ini membuktikan bahwa sistem yang dikembangkan tidak hanya secara teknis robust, tetapi juga memiliki potensi implementasi klinis yang nyata sebagai alat bantu diagnosis dini katarak, khususnya di daerah dengan keterbatasan tenaga medis spesialis mata.